

HealthSearch — Motor de Busca Híbrido

Relatório Técnico — Desafio Integrador

Aluno: Vinícius Vieira de Lima
Disciplina: Tendências em Ciência da Computação — Recuperação de Informação / PLN
Professor: Me. Ricardo Roberto de Lima

1. Objetivo

Implementar um motor de busca híbrido sobre um corpus fixo de 6 documentos clínicos, combinando recuperação léxica (BM25) e semântica (embeddings vetoriais) por meio de Reciprocal Rank Fusion (RRF), com interface interativa em Streamlit.

2. Arquitetura

O sistema segue um pipeline de 4 etapas: pré-processamento, busca léxica, busca semântica e fusão de ranks, conforme ilustrado abaixo.




Figura 1 — Pipeline do motor de busca híbrido.

3. Pré-processamento

Normalização em minúsculas, remoção de acentuação (via *unicodedata*) e pontuação, tokenização por espaço e remoção de stopwords em português (lista customizada de 40 termos). Cada documento gera duas representações: texto original (exibido na interface) e tokens (consumidos pelo BM25).

4. Motor léxico (BM25)

Implementado com a biblioteca *rank_bm25* (algoritmo Okapi BM25). Os parâmetros *k1* (saturação de frequência de termo) e *b* (normalização por tamanho de documento) são ajustáveis via sliders na interface, permitindo observar em tempo real como cada um afeta o ranking — reduzir *b* para 0, por exemplo, remove a penalização de documentos longos.

5. Motor semântico

Cada documento e a query são convertidos em vetores de 384 dimensões pelo modelo multilíngue *paraphrase-multilingual-MiniLM-L12-v2* (sentence-transformers). A similaridade é calculada via cosseno entre vetores normalizados, capturando relações semânticas que o BM25 não alcança — por exemplo, associar "infarto" a "síndrome coronariana aguda" mesmo sem sobreposição literal de termos.

6. Fusão híbrida (RRF)

Os dois rankings são combinados exclusivamente pela posição (rank), e não pelo score bruto, evitando comparar escalas incompatíveis (o score do BM25 é ilimitado, o cosseno varia de -1 a 1):

$$\text{Score}_{RRF}(D) = \alpha \cdot 1 / (k_{rrf} + \text{Rank}_{BM25}(D)) + (1 - \alpha) \cdot 1 / (k_{rrf} + \text{Rank}_{Sem}(D))$$

com $k_{rrf} = 60$ (constante de suavização padrão da literatura) e α ajustável via slider, controlando o peso relativo entre léxico e semântico.

7. Bônus — Re-ranking com Cross-Encoder

Os 3 melhores resultados do RRF são reordenados por um cross-encoder multilíngue (*cross-encoder/mmarco-mMiniLMv2-L12-H384-v1*), que avalia o par (query, documento) diretamente — mais preciso que embeddings isolados, porém computacionalmente caro, por isso restrito ao Top-3.

8. Resultados de teste

Query de teste: "infarto do miocárdio", com $k1 = 1.5$, $b = 0.75$, $\alpha = 0.5$.



Figura 2 — Resultados ranqueados pelo RRF na interface.

O resultado ilustra o valor da fusão: "Farmacologia Cardíaca" ficou em 1º lugar geral mesmo sendo apenas 3º no BM25, por ter ficado 1º no semântico — enquanto "Hipertensão Arterial", 1º no léxico (menção literal ao termo), caiu para 3º por ranquear pior no semântico (4º). Isso confirma que o RRF está de fato balanceando os dois sinais, não apenas repetindo um deles.

9. Interface

Construída em Streamlit, com sliders de parâmetros na barra lateral, campo de busca central, e duas abas: "Resultados" (lista ranqueada com scores e ranks individuais de cada método) e "Comparação de rankings" (gráfico de barras comparando a posição de cada documento nos três métodos).




Figura 3 — Comparação de rankings por documento (BM25, Semântico e RRF final).

10. Conclusão

O sistema demonstra que a combinação de sinais léxicos e semânticos, fundidos via RRF, produz rankings mais robustos que qualquer método isolado — especialmente relevante em domínios como o clínico, onde terminologia técnica e sinônimos coexistem.